Komputerowa analiza szeregów czasowych

2026/2027

Lista 1

1. Plik "zadanie1.csv" zawiera dane dotyczące studentów przygotowujących się do egzaminu. Pierwsza kolumna oznacza średnią liczbę godzin nauki w tygodniu, natomiast druga to średni wynik uzyskany w serii testów próbnych, wyrażony w procentach.

a) Oblicz podstawowe statystyki opisowe obu zmiennych oraz współczynnik korelacji liniowej Pearsona. Czy na podstawie tej wartości możesz wnioskować o zasadności zastosowania modelu liniowego?

b) Narysuj wykres rozproszenia zmiennej Y względem zmiennej X. Na podstawie wykresu zaproponuj postać zależności pomiędzy zmiennymi X i Y.

c) Wskaż obserwacje, które na podstawie wykresu mogą być nietypowe lub mogą mieć szczególny wpływ na dopasowany model. Jak je zinterpretujesz w kontekście analizowanych danych?

2. Analizujemy model regresji liniowej

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \qquad i = 1, 2, \ldots, n.$$

a) Rozważamy estymatory MNK parametrów β_0 oraz β_1. Zaimplementuj samodzielnie estymatory wyznaczone na wykładzie.

b) Zastosuj własną implementację do danych z zadania 1. Porównaj otrzymane współczynniki z wynikami uzyskanymi za pomocą gotowej funkcji regresji liniowej.

c) Narysuj dane na wykresie rozproszenia oraz nanieś na wykres otrzymaną prostą regresji.

d) Zinterpretuj wartość współczynnika kierunkowego $\widehat{\beta}_1$ w kontekście analizowanych danych.

3. Dla modelu dopasowanego w zadaniu 2 wyznacz wartości przewidywane

$$\widehat{y}_i = \widehat{\beta}_0 + \widehat{\beta}_1 x_i$$

oraz residua

$$e_i = y_i - \widehat{y}_i.$$

a) Narysuj residua e_i względem wartości x_i, względem wartości przewidywanych $\widehat{y}_i$ oraz histogram residuów. Sprawdź czy na wykresach widoczna jest systematyczna struktura residuów.

b) Zaproponuj prostą regułę identyfikacji obserwacji nietypowych. Usuń obserwacje wskazane przez metodę i ponownie dopasuj model regresji. Porównaj współczynniki regresji przed i po usunięciu obserwacji oraz wykonaj wekresy residiuów analogiczne do tych z a).

4. Wygeneruj $n = 100$ obserwacji według modelu

$$Y_i = 2 + 0.5 x_i + \varepsilon_i, \qquad \varepsilon_i \sim N(0, 1),$$

przyjmując wartości x_i z ustalonego przez siebie przedziału. Do otrzymanego zbioru dodaj:

a) PRZYPADEK 1: obserwację o typowej wartości x, ale bardzo nietypowej wartości y;

b) PRZYPADEK 2: obserwację o wartości x znacznie oddalonej od pozostałych wartości x_i, ale leżącą w pobliżu rzeczywistej prostej regresji;

c) PRZYPADEK 3: obserwację o wartości x znacznie oddalonej od pozostałych wartości x_i i jednocześnie nietypowej wartości y.

Dla każdego przypadku:

- narysuj wykres rozporszenia zaznacząc nową obserwacje innym znacznikiem;
- dopasuj model MNK przed i po dodaniu nowej obserwacji, narysuj obie proste na wykresie;
- porównaj wartości $\widehat{\beta}_0$ i $\widehat{\beta}_1$;
- wyznacz wartość residuum, wartości dźwigni (*leverage*) oraz odległość Cooka po dodaniu nowej obserwacji.

Oceń wpływ obserwacji rozważanych w a), b) i c) na położenie prostej regresji. Na podstawie wyników spróbuj wyjaśnić różnicę pomiędzy obserwacją odstającą a obserwacją mającą duży wpływ na dopasowany model.

5. Rozważ dane z pliku "zadanie5.txt" dołączonego do listy.

a) Narysuj wykres rozproszenia zmiennej Y względem zmiennej X. Dopasuj do danych model liniowy

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i.$$

Narysuj wykres residuów względem wartości przewidywanych i oceń, czy w residuach widoczna jest systematyczna struktura.

b) Na podstawie wykresu danych zaproponuj transformację zmiennych, która może prowadzić do zależności liniowej, a następnie dopasuj model regresji liniowej do odpowiednio przetransformowanych danych. Wyznacz parametry modelu. Przedstaw otrzymaną zależność na wykresach w przetransformowanej oraz w oryginalnej skali zmiennych.

c) Przeanalizuj residua modelu dopasowanego do danych po transformacji. Czy transformacja poprawiła strukturę residuów?